AI – TECH

SKRYPT DO LABORATORIUM

PRZETWARZANIE MULTIMEDIÓW W SYSTEMACH DECYZYJNYCH

LABORATORIUM 4:

Przegląd algorytmów uczących się metryk dystansu dla danych akustycznych

Adam Kurowski

Projekt współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Rozwoju Regionalnego
Program Operacyjny Polska Cyfrowa na lata 2014-2020,
Oś Priorytetowa nr 3 "Cyfrowe kompetencje społeczeństwa" Działanie nr 3.2 "Innowacyjne rozwiązania na rzecz aktywizacji cyfrowej"
Tytuł projektu: „Akademia Innowacyjnych Zastosowań Technologii Cyfrowych (AI Tech)”

1. Zagadnienia wstępne

1.1.Wymagania w odniesieniu do studenta

W ramach przygotowania do zajęć, student powinien powtórzyć lub zapoznać się z podstawowymi zagadnieniami związanymi z analizą reprezentacji, metrykami dystansu i ogólną wiedzą dotyczącą programowania. Przed przystąpieniem do wykonania ćwiczenia zaleca się:

- powtórzenie wiedzy nabytej w czasie wykładów,
- zapoznanie się (przed ćwiczeniem) z instrukcją do ćwiczenia ilustrującą podstawowe zagadnienia z zakresu tematyki ćwiczenia.

Ponadto wymagana jest od studenta:

- podstawowa umiejętność programowania,
- podstawowa znajomość języka Python,
- podstawowa znajomość algorytmów uczenia maszynowego przedstawionych w trakcie trwania wykładów
- umiejętność rozwiązywania problemów.

Wyżej wymienione wymagania bazują na wiedzy i umiejętności jakie studenci powinni zdobyć w czasie edukacji na I poziomie studiów oraz w trakcie trwania 2. semestru studiów II stopnia. W przeciwnym przypadku studenci powinni nadrobić samodzielnie stosowny materiał.

1.2.Wymagania w odniesieniu do stanowiska laboratoryjnego

Stanowisko laboratoryjne powinno być wyposażone w komputer z dostępem do sieci komputerowej oraz z następującymi zasobami:

- przykładowe programy (kody programów) podane w załączniku
- zainstalowany język Python w wersji przynajmniej 3.6.5
- Jupyter Notebook
- biblioteki niezbędne do realizacji ćwiczenia
- przeglądarka WWW.

Wykaz bibliotek języka Python wraz z numerami wersji i odnośnikami URL do ich dokumentacji w formie on-line zamieszczony jest poniżej:

Nazwa biblioteki	**Wersja**	**Odnośnik do dokumentacji**
Matplotlib	1.18.1	https://matplotlib.org/
NumPy	3.0.3	https://numpy.org/doc/stable/reference/
Pandas	0.24.1	https://pandas.pydata.org/
SciPy	1.5.4	https://docs.scipy.org/doc/scipy/reference/
Scikit-learn	6.1.0	https://scikit-learn.org/stable/

Przed przystąpieniem do wykonywania ćwiczenia warto zapoznać się z ogólnymi opisami narzędzi dostępnymi we wspomnianych bibliotekach, gdyż często znajduje się tam wiele gotowych, przydatnych i co najważniejsze – szeroko używanych, przetestowanych narzędzi realizujących różne skomplikowane zadania. Pozwala to na uniknięcie implementowania od początku algorytmów, które już wcześniej zostały przez kogoś zaprogramowane w dobry, szeroko zweryfikowany przez użytkowników biblioteki sposób.

Istnieje możliwość realizacji ćwiczenia w zewnętrznym środowisku Google Colaboratory na platformie Google, gdzie wymagane jest od użytkownika posiadanie konta Google, natomiast nie ma potrzeby konfiguracji środowiska.

1.3.Cele ćwiczenia

Celem ćwiczenia jest praktyczna demonstracja wiedzy teoretycznej, przedstawionej w ramach wykładów. Realizując ćwiczenie laboratoryjne studenci zdobędą szereg nowych umiejętności w zakresie poprawnego doboru i używania algorytmów uczących się metryk dystansu. Zademonstrowane zostanie także praktyczne wykorzystanie tego typu algorytmów do wyszukiwania i klasyfikowania wzorców.

1.4. Spodziewane efekty kształcenia - umiejętności i kompetencje:

Studenci w ramach zajęć nabędą wiedzę dotyczącą między innymi następujących zadań:

- przygotowania danych do analizy algorytmami uczącymi się metryk dystansu
- przeprowadzać trening sieci neuronowych na danych akustycznych wykorzystując metodę triplet loss
- analizować jakość reprezentacji wytwarzanych przez sieci trenowane wyżej wymienionymi metodami,
- wykorzystywać wyuczone metryki dystansu oraz sposoby generowania reprezentacji wzorców do ich wyszukiwania i klasyfikacji.

1.5.Metody dydaktyczne

Zadanie rozpocznie się od konfiguracji środowiska programistycznego, którym może być zarówno środowisko on-line takie jak usługa Google Colaboratory, jak i lokalnie uruchamiane oprogramowanie Jupyter. Dalsze działania odbywać się będą na podstawie dodatkowych materiałów i demonstracji prowadzącego, studenci będą wykonywać zadania przygotowane w postaci interaktywnych dokumentów Jupytera. Konieczne jest zarówno przyswojenie treści przekazywanych przez prowadzącego, jak i znajomość wstępnych, podstawowych zagadnień niezbędnych do zrozumienia

omawianych tematów. Na początku przedstawiane są proste problemy i demonstracje, kolejne zadania są coraz bardziej skomplikowane, przedstawiają coraz bardziej zaawansowane pojęcia, oraz wymagają bardziej intensywnego i kreatywnego zaangażowania ze strony wykonującego ćwiczenie studenta.

Wszystkie kody źródłowe programów wpisuje w dokumencie elektronicznym (lub pokazuje prowadzącemu), który jednocześnie staje się sprawozdaniem z ćwiczenia laboratoryjnego.

1.5.Zasady oceniania

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. W trakcie realizacji ćwiczenia możliwe jest przydzielenie przez prowadzącego dodatkowych zadań oraz zadawanie pytań dotyczących ćwiczenia. Premiowane są także wszelkie próby wyciągnięcia i uogólnienia wniosków wypływających z wykonywanych ćwiczeń. Mogą one dotyczyć zarówno aspektów teoretycznych, jak i praktycznych wykonywanych analiz.

Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonania. Maksymalna liczba punktów wynosi 10.

Wykaz literatury podstawowej do ćwiczenia:

Wykaz literatury podstawowej:

1.	Skrypt z materiałami do przedmiotu „Przetwarzanie multimediów w systemach dezycyjnych”
2.	Materiały do przedmiotu opracowane w formie edukacji na odległość, dostęp: https://enauczanie.pg.edu.pl/moodle/course/view.php?id=12525
3.	Aurélien Géron, Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow. Wydanie II, Helion 2020
4.	Sebastian Raschka, Python. Uczenie maszynowe, Helion 2017
5.	Aggarwal C., Hinneburg A., Keim A., On the Surprising Behavior of Distance Metrics in High Dimensional Space. In: Van den Bussche J., Vianu V. (eds) Database Theory — ICDT 2001. ICDT 2001. Lecture Notes in Computer Science, vol 1973. Springer, Berlin, Heidelberg 2001. https://doi.org/10.1007/3-540-44503-X_27
6.	Wang, F., Liu, H. Understanding the behaviour of contrastive loss. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 2495-2504). 2021
7.	Hermans, A., Beyer, L., & Leibe, B. (2017). In defense of the triplet loss for person re-identification. arXiv preprint arXiv:1703.07737.

Wykaz literatury uzupełniającej:

1.	Dokumentacja bibliotek wymienionych w sekcji dotyczącej wymagań względem stanowiska
2.	Dokumentacja platformy Colaboratory: https://colab.research.google.com/notebooks/intro.ipynb#scrollTo=-gE-Ez1qtyIA
3.	Francois Chollet, Deep Learning. Praca z językiem Python i biblioteką Keras, Helion 2019

2. Przebieg ćwiczenia

L.p.	Zadanie
1.	Zapoznanie się z instrukcją laboratoryjną (przed ćwiczeniem)
2.	Wprowadzenie kierownika ćwiczenia. Zapoznanie się uczestników ze stosowanymi programami, przegląd dokumentacji (10 min.)
3.	Badanie algorytmu contrastive loss (30 min.)
4.	Badanie algorytmu triplet loss (30 min.)
5.	Opracowanie klasyfikatorów progowych bazujących na badanych wcześniej modelach (30 min.)
6.	Wykorzystanie wybranego algorytmu do zrealizowania poszukiwania wzorca podobnego do przedstawionego przykładu (20 min.)
7.	Przesłanie/pokazanie zbioru dokumentów/programów do oceny (10 min.)

UWAGI

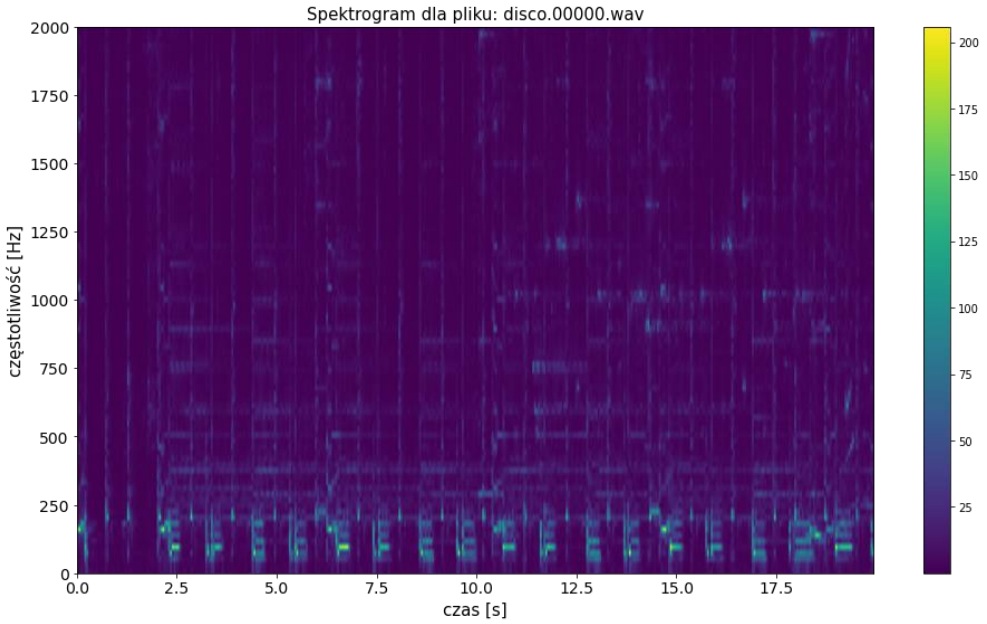
Przed przystąpieniem do ćwiczenia należy utworzyć własny, unikalny katalog w lokalizacji wskazanej przez prowadzącego, a następnie należy tam umieścić pliki testowe oraz własne implementacje kodu programów dokonujących rozwiązanie zadanie. Należy pracować wyłącznie na wykonanej kopii plików.

3. Wprowadzenie do ćwiczenia

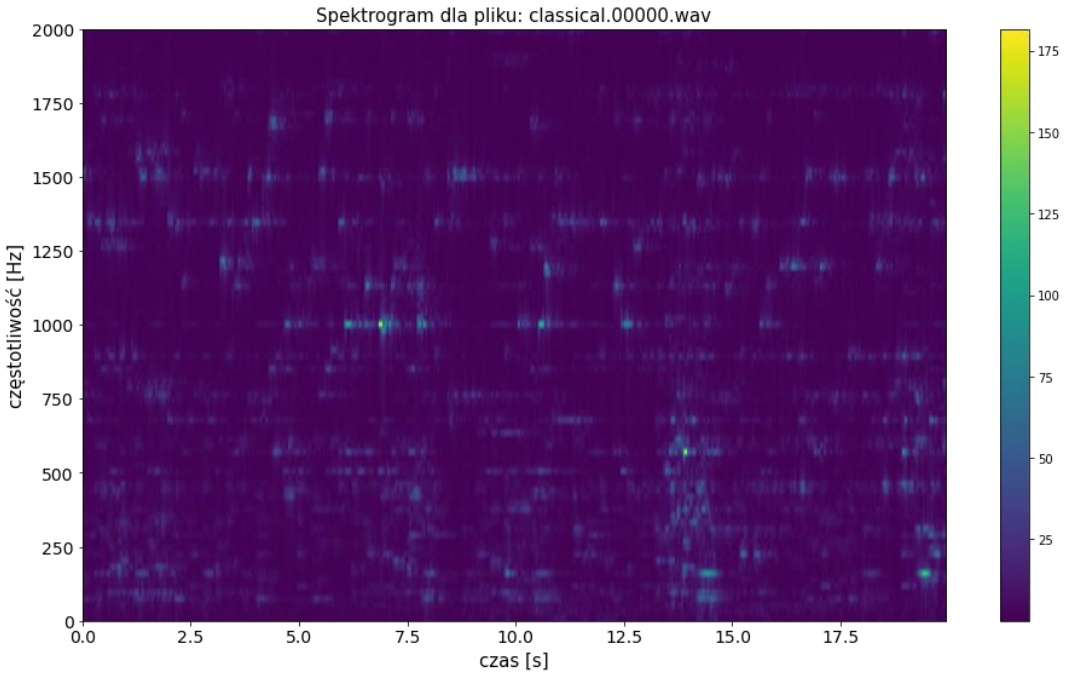
Wykorzystanie uczenia maszynowego do analizy danych akustycznych wymaga specjalnego potraktowania danych wejściowych. Zwykle uruchamiając algorytmy uczące się metryk dystansu chcemy móc skorzystać z warstw splotowych na zasadach takich jak dla przetwarzania obrazów. Niestety – dane akustyczne stanowią jednowymiarowy typ danych. W przypadku sygnału wielokanałowego także nie jest możliwe zastosowanie dwuwymiarowych warstw splotowych. Z tego względu konieczne jest zastosowanie specjalnych technik przetwarzania wstępnego, które przekształcą jednowymiarowy strumień danych do zestawu danych dwuwymiarowych.

Najprostszym przekształceniem, które można wykorzystać do tego celu jest **transformacja Fouriera**. W szczególności często wykorzystywana jest jej dyskretna wersja obliczona algorytmem FFT. Sygnał

akustyczny poddany tego typu przekształceniu przeniesiony jest do dziedziny częstotliwości. W tej postaci możliwe jest odczytanie, z jakich składowych częstotliwościowych (potocznie – z jakich niskich i wysokich dźwięków) składa się sygnał. Jeżeli podzielimy sygnał na ramki odpowiadające następującym po sobie momentom i poddamy je przekształceniu Fouriera otrzymamy tzw. **spektrogram.** Jest to postać sygnału bardzo dobrze nadająca się do zastosowania w uczeniu maszynowym, gdyż jest to dwuwymiarowe przedstawienie sygnału akustycznego. Jest on z jednej strony intuicyjny w interpretacji – obrazowo można zidentyfikować w nim zmienność różnych komponentów sygnału w czasie, z drugiej strony – nadaje się do przetwarzania technikami oryginalnie opracowanymi do przetwarzania obrazów. Przykład spektrogramów wygenerowanych dla sygnałów akustycznych przedstawiony jest na rys. 1 i rys. 2.



Rysunek 1. Spektrogram utworu z gatunku muzyki dyskotekowej – widoczna jest charakterystyczna struktura utworu, rytmicznie powtarzające się skupiska energii odpowiadające dźwiękowi niskiego bębna, tzw. stopy oraz reakcja innych instrumentów perkusyjnych współgrających ze stopą.

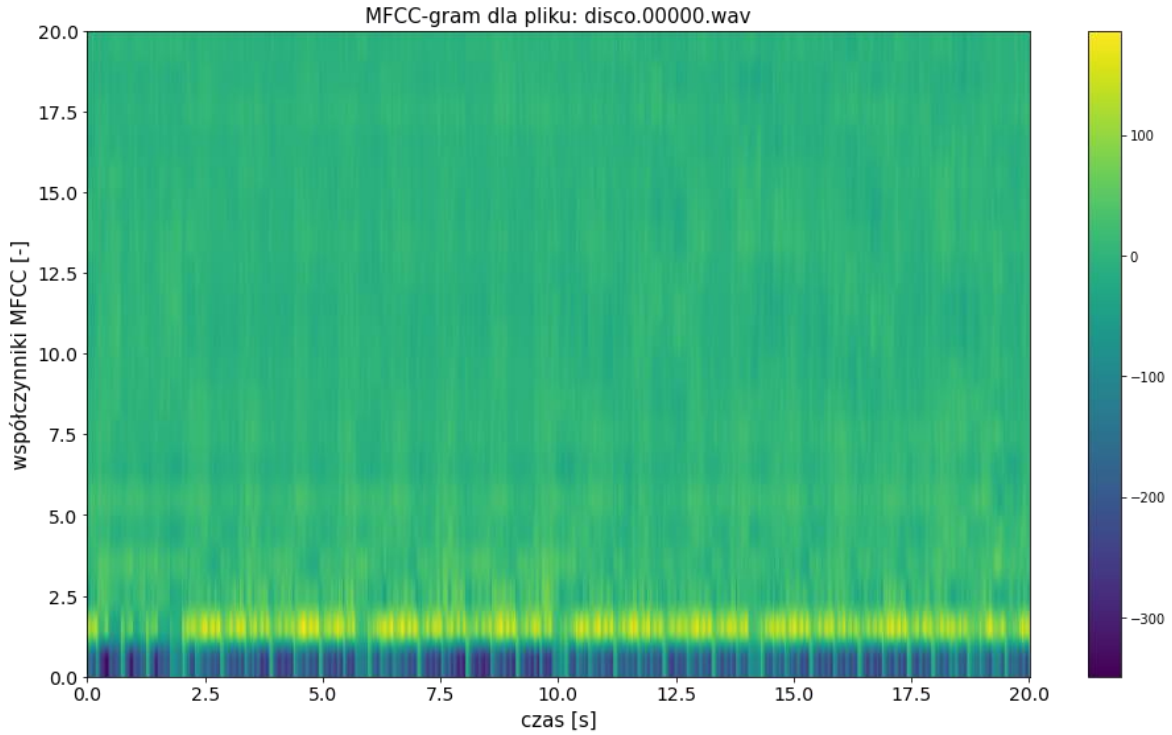


Rysunek 2. Spektrogram utworu z gatunku muzyki klasycznej – w porównaniu do muzyki disco widoczny jest brak sztywnej struktury oraz wyższej wysokości dźwięki (znajdujące się wyżej na osi y). Po właśnie takich różnicach w strukturze możliwe jest rozróżnienie od siebie gatunków muzycznych.

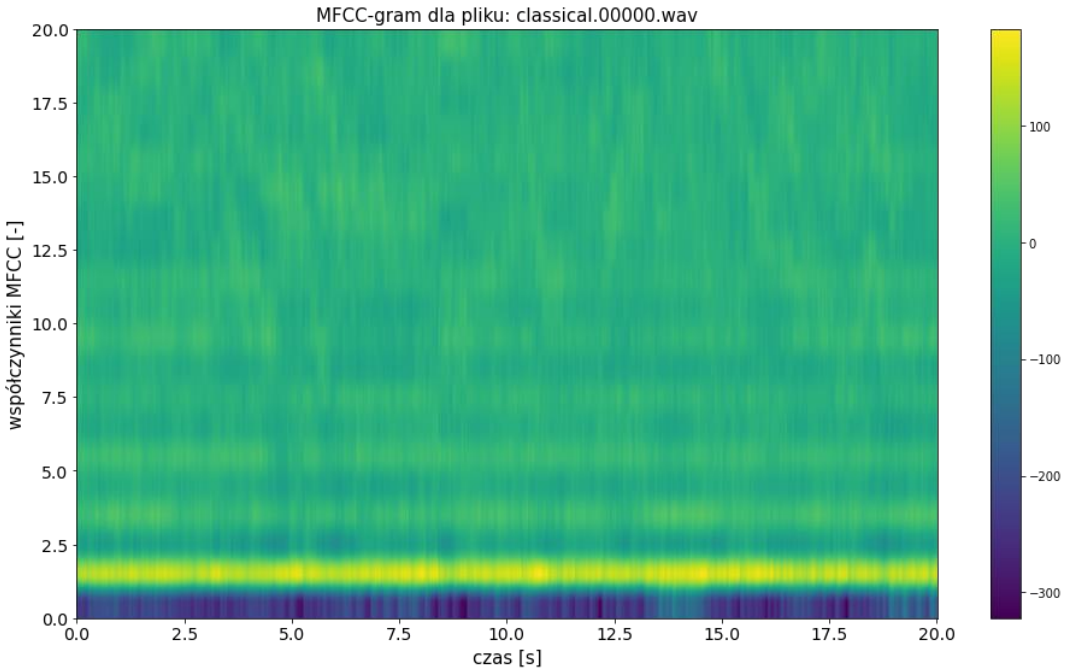
Oprócz spektrogramów istnieją bardziej zaawansowane sposoby przedstawienia sygnałów akustycznych. Jednym z takich zaawansowanych sposobów są współczynniki mel-cepstralne (MFCC) umieszczone na osi czasu na podobnej zasadzie, jak FFT. W takim przypadku możemy mówić o tak zwanym MFCC-gramie. Przedstawienie to ma tę zaletę, że uwzględnia dwa ważne zjawiska związane z percepcją sygnałów akustycznych przez człowieka

- logarytmiczną percepcję wrażenia wysokości dźwięku, to dlatego w codziennym życiu wygodnie nam porównywać wysokość dźwięku mówiąc ile razy jeden dźwięk jest wyższy od drugiego,
- wrażliwość na częstotliwość podstawową, czyli to jak szybko w widmie powtarzają się poszczególne jego prążki – jest to proces umożliwiający ludzkiemu zmysłowi słuchu określić np. barwę głosu rozmówcy.

W porównaniu do spektrogramów współczynniki MFCC charakteryzują się często lepszymi rezultatami, gdy wykorzystywane są jako metoda parametryzacji sygnałów akustycznych. W zamian niestety – są trudniejsze do interpretacji wizualnej. Przykłady współczynników MFCC odpowiadających wizualizacjom z rys. 1 i 2 przedstawione są na rys. 3 i rys. 4.



Rysunek 2. MFCC-gram wygenerowany dla muzyki w gatunku disco.



Rysunek 2. MFCC-gram wygenerowany na podstawie fragmentu muzyki klasycznej.

4. Zadania do wykonania

W trakcie laboratorium do wykonania są następujące ćwiczenia:

1. Uruchom notatnik *P1_analiza_widmowa.ipynb* i zapoznaj się z nastawami możliwymi do modyfikacji. Wybierz **4 gatunki muzyczne** ze zbioru GTZAN i zwizualizuj ich widma oraz MFCC-gramy, zamieść je w sprawozdaniu.
    a. **Jakie różnice widoczne** są pomiędzy wybranymi przykładami wizualizacji gatunków muzycznych? Czy bardziej **widoczne są one w spektrogramach, czy w MFCC-gramach?**
    b. Spektrogram charakteryzuje są tą własnością, że im dłuższą ramkę analizy wybierzemy, tym mamy większą rozdzielczość na osi częstotliwości, jednak okupujemy to zmniejszoną

rozdzielczością na osi czasu. **Ustaw wartość współczynnika nakładania się ramek (nakładkowania) na 0 (jeśli masz inną wartość). Pokaż w sprawozdaniu przykład spektrogramu o wysokiej rozdzielczości częstotliwościowej i wysokiej częstotliwości czasowej** (jest to przykład tzw. zasady nieoznaczoności).

c. Dla przykładu o niskiej rozdzielczości czasowej zwiększ ją sztucznie poprzez zwiększenie współczynnika nakładkowania. **Czy po zwiększeniu rozdzielczości zauważasz jakieś artefakty? Czy jest to sposób, który może całkowicie zastąpić zmniejszenie długości ramki?**

2. Korzystając z notatnika *P2_przetwarzanie_GTZAN.ipynb* wytrenuj algorytmem triplet loss sieć neuronową uczącą się metryk dystansu na podstawie **spektrogramów** sygnałów zawartych w zbiorze GTZAN. Przetestuj kilka architektur i nastaw treningu (**dopuszczalne jest testowanie różnych nastaw w grupach**). **Zachowaj na później wytrenowany w ten sposób model. W sprawozdaniu opisz architekturę sieci i nastawy, a także zapisz wizualizację przestrzeni reprezentacji. Opisz, jak rozkładają się w przestrzeni poszczególne gatunki muzyczne i czy da się logicznie uzasadnić taki właśnie rozkład punktów.**
3. Korzystając z notatnika *P2_przetwarzanie_GTZAN.ipynb* wytrenuj algorytmem triplet loss sieć neuronową uczącą się metryk dystansu na podstawie **współczynników MFCC** sygnałów zawartych w zbiorze GTZAN. Przetestuj kilka architektur i nastaw treningu (**dopuszczalne jest testowanie różnych nastaw w grupach**). **Zachowaj na później wytrenowany w ten sposób model. W sprawozdaniu opisz architekturę sieci i nastawy, a także zapisz wizualizację przestrzeni reprezentacji. Opisz, jak rozkładają się w przestrzeni poszczególne gatunki muzyczne i czy da się logicznie uzasadnić taki właśnie rozkład punktów.**
4. Mając do dyspozycji modele i notatniki z punktów 2 oraz 3 – wygeneruj wytrenowaną siecią reprezentacje odpowiadające zmiennych przechowującym przykłady treningowe i testowe, a

następnie **zaprogramuj klasyfikator działający na zasadzie k najbliższych sąsiadów. Zmierz skuteczności i macierze pomyłek dla parametryzacji za pomocą spektrogramów i MFCC-gramów. Krótko skomentuj uzyskane wyniki.**

5. Forma i zawartość sprawozdania

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. Szczególnie premiowane będą dodatkowe wnioski i obserwacje poczynione samodzielnie przez osoby wykonujące ćwiczenie. Zarówno te dotyczące różnego rodzaju teoretycznych aspektów wykonywanych czynności, jak i ich możliwych praktycznych zastosowań. Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonania. Maksymalna liczba punktów wynosi 10.

Dodatki:

Pliki instruktażowe oraz pliki z danymi, niezbędne do wykonania ćwiczenia laboratoryjnego:

1) *P1_analiza_widmowa.ipynb*
2) *P2_przetwarzanie_GTZAN.ipynb*